

Crecimiento de DIAMOnD por celda de proyección

OptimusKG en Neo4j. Informe generado el 2026-09-11

Qué se corrió

Una celda es un paso del algoritmo: dada un ancla de tipo A, se cosechan sus vecinos de tipo B y se corre DIAMOnD dentro del plano B-B, la red que forman los nodos de tipo B entre sí. El salto entre tipos lo hace la cosecha, DIAMOnD nunca cambia de tipo.

Con dos tipos hay 2 celdas repartidas en 2 planos.
Por celda, 50 anclas por bin de tamaño del conjunto semilla (bins por rango de semillas efectivas en el plano).

Por caso: una corrida real de 100 iteraciones, 20 controles uniformes, 20 controles con semillas apareadas por clase de grado (9)

El ancla se excluye de la red solo en las cuatro celdas del mismo tipo, que son las únicas donde pertenece al plano. En las cruzadas es de otro tipo y no está. Los nodos genéricos de la taxonomía no se excluyen.

La comparación real contra control es visual: la banda es la media más o menos un desvío sobre los 20 sorteos.

Los planos donde corre DIAMOnD

gene	Gene-Gene vía PPI
disease	Disease-Disease vía DISEASE_DISEASE, filtrado por NOT a.es_grupo_bert AND NOT b.es_grupo_bert

Sin umbral de evidencia: las asociaciones gen-enfermedad son las curadas de DisGeNET que trae el grafo de Ingrid y no tienen score. Los grupos BERT quedan fuera de todo.


Seed de todos los sorteos: 42

Casos corridos por celda

disease_a_gene	ancla Disease	plano gene	150 casos
gene_a_disease	ancla Gene	plano disease	150 casos


CCDF de grado por capa y tipo de nodo (log-log)

disease_gene




CCDF de grado de cada plano homogéneo (log-log)

plano gene (PPI)




plano disease (DISEASE_DISEASE)



plano gene (PPI): ley de crecimiento y fracción de semillas en la LCC del módulo


frac. de semillas en la LCC



el nulo gana = el promedio de su curva a lo largo de las 100 iteraciones iguala o supera al de la corrida real de esa ancla (promediando sus 20 sorteos). El empate cuenta para el nulo


plano gene (PPI): recall cruzado contra el nulo de semillas apareadas

recall de semillas escondidas






plano gene (PPI): recall cruzado en los tres niveles de remoción

recall de semillas escondidas



plano gene (PPI): tamaño de la componente conexas mayor del módulo


nodos en la componente conexas mayor



el nulo gana = el promedio de su curva a lo largo de las 100 iteraciones iguala o supera al de la corrida real de esa ancla (promediando sus 20 sorteos). El empate cuenta para el nulo

plano disease (DISEASE_DISEASE): ley de crecimiento y fracción de semillas en la LCC del módulo


frac. de semillas en la LCC




el nulo gana = el promedio de su curva a lo largo de las 100 iteraciones iguala o supera al de la corrida real de esa ancla (promediando sus 20 sorteos). El empate cuenta para el nulo

plano disease (DISEASE_DISEASE): recall cruzado contra el nulo de semillas apareadas

recall de semillas escondidas






plano disease (DISEASE_DISEASE): recall cruzado en los tres niveles de remoción



recall de semillas escondidas

plano disease (DISEASE_DISEASE): tamaño de la componente conexas mayor del módulo

nodos en la componente conexas mayor



el nulo gana = el promedio de su curva a lo largo de las 100 iteraciones iguala o supera al de la corrida real de esa ancla (promediando sus 20 sorteos). El empate cuenta para el nulo

Crecimiento de DIAMOnD por celda: tabla resumen

celda	origen	plano	relacion_cosecha	bin	casos	n_semillas_mediana	iteraciones_alcanzadas_mediana	frac_semillas_lcc_inicial_real	frac_semillas_lcc_final_real	frac_desconectadas_integradas	frac_semillas_lcc_final_apareado	fuera_de_clase_medio	lcc_tam_final_real	salida_de_banda	recall_final_medio	recall_final_ic95	recall_final_azar	recall_final_apareado	iteracion_meseta_recall
disease_a_gene	Disease	gene	GDA	alto	50	37.0	100.0	0.2353	0.5096	0.3586	0.3199	0.001	134.1	0	0.0749	0.0242	0.0073	0.0145	86
disease_a_gene	Disease	gene	GDA	bajo	50	6.0	100.0	0.2622	0.5125	0.3393	0.3785	0.0	84.9	0	0.092	0.0525	0.0072	0.0072	62
disease_a_gene	Disease	gene	GDA	medio	50	11.0	100.0	0.2269	0.4892	0.3394	0.3694	0.0	99.0	0	0.1116	0.0385	0.0072	0.0193	88
gene_a_disease	Gene	disease	GDA	alto	50	18.5	100.0	0.219	0.4372	0.2794	0.1783	0.0	82.4	0	0.2696	0.0376	0.0216	0.0283	86
gene_a_disease	Gene	disease	GDA	bajo	50	5.0	100.0	0.4667	0.6433	0.3312	0.313	0.0	81.8	0	0.366	0.0892	0.0215	0.0248	77
gene_a_disease	Gene	disease	GDA	medio	50	7.5	100.0	0.3293	0.5999	0.4035	0.2504	0.0	80.6	0	0.326	0.0689	0.0294	0.0292	87

celda: el paso del algoritmo: desde que tipo se cosecha y en que plano se expande

origen: tipo del ancla, la entidad de la consulta

plano: la red homogénea donde corre DIAMOnD

relacion_cosecha: la relación por la que el ancla trae sus semillas

bin: tamaño del conjunto semilla (tercil por rango de semillas efectivas en la celda)

casos: anclas corridas en la celda

n_semillas_mediana: mediana de semillas efectivas de los casos de la celda

iteraciones_alcanzadas_mediana: mediana, entre las corridas reales del bin, de la última iteración en que DIAMOnD agregó un nodo. Menor que el presupuesto cuando la red se agota antes

frac_semillas_lcc_inicial_real: fracción de semillas en la LCC en la iteración 0, antes de que DIAMOnD agregue nada, media de las corridas reales. Es la conectividad del conjunto que la celda cosecha, y lo que la expansión recibe de arranque

frac_semillas_lcc_final_real: fracción de semillas en la LCC al agotar el presupuesto, media de las corridas reales

frac_desconectadas_integradas: de las semillas que en la iteración 0 estaban fuera de la LCC, qué fracción terminó adentro: (final menos inicial) dividido (1 menos inicial). Es lo que aporta la expansión, descontando lo que ya venía conectado. En el paper de DIAMOnD este número va entre el 30% y el 60%

frac_semillas_lcc_final_apareado: ídem para las semillas de control apareadas por clase de grado (media de la banda): lo que conecta un conjunto de nodos al azar con los mismos grados que las semillas

fuera_de_clase_medio: fracción media de semillas de control que hubo que tomar de una clase de grado vecina porque la propia se agotó. 0 = apareo dentro de la clase para todas. Alta solo donde las semillas son hubs (grado 512 o más) y el plano tiene pocos

lcc_tam_final_real: tamaño de la componente conexa mayor del módulo al agotar el presupuesto, media de las corridas reales

salida_de_banda: primera iteración donde la curva real supera la banda del control apareado (media más un desvío). Vacío = nunca sale

recall_final_medio: recall de semillas escondidas al agotar el presupuesto, media de folds por casos

recall_final_ic95: semiancho del IC95 de ese recall, calculado entre las medias por ancla

recall_final_azar: recall esperable por azar en el mismo rank, con universo = la componente alcanzable desde las semillas visibles, sin ellas. En gene, disease y phenotype esa componente es casi el plano entero, así que la línea queda pegada al piso. En drug pasa lo contrario y tampoco informa: el universo tiene una mediana de 12 nodos, más chico que el presupuesto, así que la fracción se satura en 1 antes del rango del gráfico. Por eso la línea se dibuja solo hasta donde el universo se agota

recall_final_apareado: el mismo recall final medido escondiendo el 30% de un conjunto de semillas al azar del mismo grado que las reales. Es el control del recall: lo que DIAMOnD recupera por el grado solo, sin coherencia modular

iteracion_meseta_recall: primera iteración en que el recall medio del bin alcanza el 95% de su valor final. Es el criterio de corte del paper, y el número que la calibración de cada paso necesita