

Crecimiento de DIAMOnD por celda: tabla resumen

celda	origen	plano	relacion_cosecha	bin	casos	n_semillas_mediana	iteraciones_alcanzadas_mediana	frac_semillas_lcc_inicial_real	frac_semillas_lcc_final_real	frac_desconectadas_integradas	frac_semillas_lcc_final_apareado	fuera_de_clase_medio	lcc_tam_final_real	salida_de_banda	recall_final_medio	recall_final_ic95	recall_final_azar	recall_final_apareado	iteracion_meseta_recall
disease_a_gene	Disease	gene	GDA	alto	50	37.0	100.0	0.2353	0.5096	0.3586	0.3199	0.001	134.1	0	0.0749	0.0242	0.0073	0.0145	86
disease_a_gene	Disease	gene	GDA	bajo	50	6.0	100.0	0.2622	0.5125	0.3393	0.3785	0.0	84.9	0	0.092	0.0525	0.0072	0.0072	62
disease_a_gene	Disease	gene	GDA	medio	50	11.0	100.0	0.2269	0.4892	0.3394	0.3694	0.0	99.0	0	0.1116	0.0385	0.0072	0.0193	88
gene_a_disease	Gene	disease	GDA	alto	50	18.5	100.0	0.219	0.4372	0.2794	0.1783	0.0	82.4	0	0.2696	0.0376	0.0216	0.0283	86
gene_a_disease	Gene	disease	GDA	bajo	50	5.0	100.0	0.4667	0.6433	0.3312	0.313	0.0	81.8	0	0.366	0.0892	0.0215	0.0248	77
gene_a_disease	Gene	disease	GDA	medio	50	7.5	100.0	0.3293	0.5999	0.4035	0.2504	0.0	80.6	0	0.326	0.0689	0.0294	0.0292	87

celda: el paso del algoritmo: desde que tipo se cosecha y en que plano se expande

origen: tipo del ancla, la entidad de la consulta

plano: la red homogénea donde corre DIAMOnD

relacion_cosecha: la relación por la que el ancla trae sus semillas

bin: tamaño del conjunto semilla (tercil por rango de semillas efectivas en la celda)

casos: anclas corridas en la celda

n_semillas_mediana: mediana de semillas efectivas de los casos de la celda

iteraciones_alcanzadas_mediana: mediana, entre las corridas reales del bin, de la última iteración en que DIAMOnD agregó un nodo. Menor que el presupuesto cuando la red se agota antes

frac_semillas_lcc_inicial_real: fracción de semillas en la LCC en la iteración 0, antes de que DIAMOnD agregue nada, media de las corridas reales. Es la conectividad del conjunto que la celda cosecha, y lo que la expansión recibe de arranque

frac_semillas_lcc_final_real: fracción de semillas en la LCC al agotar el presupuesto, media de las corridas reales

frac_desconectadas_integradas: de las semillas que en la iteración 0 estaban fuera de la LCC, qué fracción terminó adentro: (final menos inicial) dividido (1 menos inicial). Es lo que aporta la expansión, descontando lo que ya venía conectado. En el paper de DIAMOnD este número va entre el 30% y el 60%

frac_semillas_lcc_final_apareado: ídem para las semillas de control apareadas por clase de grado (media de la banda): lo que conecta un conjunto de nodos al azar con los mismos grados que las semillas

fuera_de_clase_medio: fracción media de semillas de control que hubo que tomar de una clase de grado vecina porque la propia se agotó. 0 = apareo dentro de la clase para todas. Alta solo donde las semillas son hubs (grado 512 o más) y el plano tiene pocos

lcc_tam_final_real: tamaño de la componente conexa mayor del módulo al agotar el presupuesto, media de las corridas reales

salida_de_banda: primera iteración donde la curva real supera la banda del control apareado (media más un desvío). Vacío = nunca sale

recall_final_medio: recall de semillas escondidas al agotar el presupuesto, media de folds por casos

recall_final_ic95: semiancho del IC95 de ese recall, calculado entre las medias por ancla

recall_final_azar: recall esperable por azar en el mismo rank, con universo = la componente alcanzable desde las semillas visibles, sin ellas. En gene, disease y phenotype esa componente es casi el plano entero, así que la línea queda pegada al piso. En drug pasa lo contrario y tampoco informa: el universo tiene una mediana de 12 nodos, más chico que el presupuesto, así que la fracción se satura en 1 antes del rango del gráfico. Por eso la línea se dibuja solo hasta donde el universo se agota

recall_final_apareado: el mismo recall final medido escondiendo el 30% de un conjunto de semillas al azar del mismo grado que las reales. Es el control del recall: lo que DIAMOnD recupera por el grado solo, sin coherencia modular

iteracion_meseta_recall: primera iteración en que el recall medio del bin alcanza el 95% de su valor final. Es el criterio de corte del paper, y el número que la calibración de cada paso necesita