

# Crecimiento de DIAMOnD por celda de proyección

OptimusKG en Neo4j. Informe generado el 2026-09-11

Qué se corrió

Una celda es un paso del algoritmo: dada un ancla de tipo A, se cosechan sus vecinos de tipo B y se corre DIAMOnD dentro del plano B-B, la red que forman los nodos de tipo B entre sí. El salto entre tipos lo hace la cosecha, DIAMOnD nunca cambia de tipo.

Con dos tipos hay 2 celdas repartidas en 2 planos.  
Por celda, 50 anclas por bin de tamaño del conjunto semilla (bins por rango de semillas efectivas en el plano).

Por caso: una corrida real de 100 iteraciones, 20 controles uniformes, 20 controles con semillas apareadas por clase de grado (0-10)

El ancla se excluye de la red solo en las cuatro celdas del mismo tipo, que son las únicas donde pertenece al plano. En las cruzadas es de otro tipo y no está. Los nodos genéricos de la taxonomía no se excluyen.

La comparación real contra control es visual: la banda es la media más o menos un desvío sobre los 20 sorteos.

Los planos donde corre DIAMOnD

|         |                                                  |
|---------|--------------------------------------------------|
| gene    | Gene-Gene vía PPI                                |
| disease | Disease-Disease vía DISEASE_DISEASE DISEASE_BERT |

Sin umbral de evidencia: las asociaciones gen-enfermedad son las curadas de DisGeNET que trae el grafo de Ingrid y no tienen score. Los grupos BERT quedan fuera de todo.


Seed de todos los sorteos: 42

Casos corridos por celda

|                |               |               |           |
|----------------|---------------|---------------|-----------|
| disease_a_gene | ancla Disease | plano gene    | 150 casos |
| gene_a_disease | ancla Gene    | plano disease | 150 casos |


# CCDF de grado por capa y tipo de nodo (log-log)

disease\_gene




# CCDF de grado de cada plano homogéneo (log-log)

plano gene (PPI)




plano disease (DISEASE\_DISEASE|DISEASE\_BERT)



# plano gene (PPI): ley de crecimiento y fracción de semillas en la LCC del módulo


frac. de semillas en la LCC



el nulo gana = el promedio de su curva a lo largo de las 100 iteraciones iguala o supera al de la corrida real de esa ancla (promediando sus 20 sorteos). El empate cuenta para el nulo


# plano gene (PPI): recall cruzado contra el nulo de semillas apareadas

recall de semillas escondidas






# plano gene (PPI): recall cruzado en los tres niveles de remoción

recall de semillas escondidas



# plano gene (PPI): tamaño de la componente conexas mayor del módulo




nodos en la componente conexas mayor



el nulo gana = el promedio de su curva a lo largo de las 100 iteraciones iguala o supera al de la corrida real de esa ancla (promediando sus 20 sorteos). El empate cuenta para el nulo

# plano disease (DISEASE\_DISEASE|DISEASE\_BERT): ley de crecimiento y fracción de semillas en la LCC del módulo


frac. de semillas en la LCC



el nulo gana = el promedio de su curva a lo largo de las 100 iteraciones iguala o supera al de la corrida real de esa ancla (promediando sus 20 sorteos). El empate cuenta para el nulo


# plano disease (DISEASE\_DISEASE|DISEASE\_BERT): recall cruzado contra el nulo de semillas apareadas

recall de semillas escondidas






# plano disease (DISEASE\_DISEASE|DISEASE\_BERT): recall cruzado en los tres niveles de remoción

recall de semillas escondidas



# plano disease (DISEASE\_DISEASE|DISEASE\_BERT): tamaño de la componente conexa mayor del módulo

nodos en la componente conexa mayor



el nulo gana = el promedio de su curva a lo largo de las 100 iteraciones iguala o supera al de la corrida real de esa ancla (promediando sus 20 sorteos). El empate cuenta para el nulo

Crecimiento de DIAMOnD por celda: tabla resumen

| celda          | origen  | plano   | relacion_cosecha | bin   | casos | n_semillas_mediana | iteraciones_alcanzadas_mediana | frac_semillas_lcc_inicial_real | frac_semillas_lcc_final_real | frac_desconectadas_integradas | frac_semillas_lcc_final_apareado | fuera_de_clase_medio | lcc_tam_final_real | salida_de_banda | recall_final_medio | recall_final_ic95 | recall_final_azar | recall_final_apareado | iteracion_meseta_recall |
|----------------|---------|---------|------------------|-------|-------|--------------------|--------------------------------|--------------------------------|------------------------------|-------------------------------|----------------------------------|----------------------|--------------------|-----------------|--------------------|-------------------|-------------------|-----------------------|-------------------------|
| disease_a_gene | Disease | gene    | GDA              | alto  | 50    | 37.0               | 100.0                          | 0.2353                         | 0.5096                       | 0.3586                        | 0.3199                           | 0.001                | 134.1              | 0               | 0.0749             | 0.0242            | 0.0073            | 0.0145                | 86                      |
| disease_a_gene | Disease | gene    | GDA              | bajo  | 50    | 6.0                | 100.0                          | 0.2622                         | 0.5125                       | 0.3393                        | 0.3785                           | 0.0                  | 84.9               | 0               | 0.092              | 0.0525            | 0.0072            | 0.0072                | 62                      |
| disease_a_gene | Disease | gene    | GDA              | medio | 50    | 11.0               | 100.0                          | 0.2269                         | 0.4892                       | 0.3394                        | 0.3694                           | 0.0                  | 99.0               | 0               | 0.1116             | 0.0385            | 0.0072            | 0.0193                | 88                      |
| gene_a_disease | Gene    | disease | GDA              | alto  | 50    | 25.5               | 100.0                          | 0.167                          | 0.425                        | 0.3097                        | 0.1518                           | 0.0                  | 90.2               | 0               | 0.2047             | 0.0333            | 0.009             | 0.0134                | 93                      |
| gene_a_disease | Gene    | disease | GDA              | bajo  | 50    | 6.0                | 100.0                          | 0.3914                         | 0.603                        | 0.3476                        | 0.254                            | 0.0                  | 76.5               | 0               | 0.306              | 0.0829            | 0.009             | 0.0157                | 73                      |
| gene_a_disease | Gene    | disease | GDA              | medio | 50    | 10.0               | 100.0                          | 0.2505                         | 0.5077                       | 0.3432                        | 0.1886                           | 0.0                  | 86.6               | 0               | 0.3009             | 0.067             | 0.013             | 0.0125                | 86                      |

celda: el paso del algoritmo: desde que tipo se cosecha y en que plano se expande

origen: tipo del ancla, la entidad de la consulta

plano: la red homogénea donde corre DIAMOnD

relacion\_cosecha: la relación por la que el ancla trae sus semillas

bin: tamaño del conjunto semilla (tercil por rango de semillas efectivas en la celda)

casos: anclas corridas en la celda

n\_semillas\_mediana: mediana de semillas efectivas de los casos de la celda

iteraciones\_alcanzadas\_mediana: mediana, entre las corridas reales del bin, de la última iteración en que DIAMOnD agregó un nodo. Menor que el presupuesto cuando la red se agota antes

frac\_semillas\_lcc\_inicial\_real: fracción de semillas en la LCC en la iteración 0, antes de que DIAMOnD agregue nada, media de las corridas reales. Es la conectividad del conjunto que la celda cosecha, y lo que la expansión recibe de arranque

frac\_semillas\_lcc\_final\_real: fracción de semillas en la LCC al agotar el presupuesto, media de las corridas reales

frac\_desconectadas\_integradas: de las semillas que en la iteración 0 estaban fuera de la LCC, qué fracción terminó adentro: (final menos inicial) dividido (1 menos inicial). Es lo que aporta la expansión, descontando lo que ya venía conectado. En el paper de DIAMOnD este número va entre el 30% y el 60%

frac\_semillas\_lcc\_final\_apareado: ídem para las semillas de control apareadas por clase de grado (media de la banda): lo que conecta un conjunto de nodos al azar con los mismos grados que las semillas

fuera\_de\_clase\_medio: fracción media de semillas de control que hubo que tomar de una clase de grado vecina porque la propia se agotó. 0 = apareo dentro de la clase para todas. Alta solo donde las semillas son hubs (grado 512 o más) y el plano tiene pocos

lcc\_tam\_final\_real: tamaño de la componente conexa mayor del módulo al agotar el presupuesto, media de las corridas reales

salida\_de\_banda: primera iteración donde la curva real supera la banda del control apareado (media más un desvío). Vacío = nunca sale

recall\_final\_medio: recall de semillas escondidas al agotar el presupuesto, media de folds por casos

recall\_final\_ic95: semiancho del IC95 de ese recall, calculado entre las medias por ancla

recall\_final\_azar: recall esperable por azar en el mismo rank, con universo = la componente alcanzable desde las semillas visibles, sin ellas. En gene, disease y phenotype esa componente es casi el plano entero, así que la línea queda pegada al piso. En drug pasa lo contrario y tampoco informa: el universo tiene una mediana de 12 nodos, más chico que el presupuesto, así que la fracción se satura en 1 antes del rango del gráfico. Por eso la línea se dibuja solo hasta donde el universo se agota

recall\_final\_apareado: el mismo recall final medido escondiendo el 30% de un conjunto de semillas al azar del mismo grado que las reales. Es el control del recall: lo que DIAMOnD recupera por el grado solo, sin coherencia modular

iteracion\_meseta\_recall: primera iteración en que el recall medio del bin alcanza el 95% de su valor final. Es el criterio de corte del paper, y el número que la calibración de cada paso necesita